

Темы кейсов

Обнаружение AI-assisted spam campaigns в электронной почте на основе multi-signal анализа.....	1
Метод обобщения результатов глубокого анализа фишинговых веб-страниц и вложений в компактные признаки для локальной антиспам-фильтрации	3
Разработка сверхлегковесной CNN-модели для выявления подозрительных писем по MIME-заголовкам в локальном антиспам-движке.....	5

Обнаружение AI-assisted spam campaigns в электронной почте на основе multi-signal анализа

Цель: Разработать подход для выявления спам-писем и спам-кампаний, где ИИ мог использоваться не только для написания текста, но и для создания или модификации других элементов письма: темы, СТА, HTML, изображений, QR-кодов, ссылок, шаблонов и вариаций внутри кампании.

Ключевая идея: не искать только “текст, написанный ИИ”, а выявлять признаки использования ИИ в процессе создания письма или кампании.

Научная опора:

- Do Spammers Dream of Electric Sheep?
<https://www.cs.columbia.edu/~junfeng/papers/ai-email-imc25.pdf>
- Machine Learning and Watermarking for Accurate Detection of AI-Generated Phishing Emails
<https://www.mdpi.com/2079-9292/14/13/2611>
- SpearBot
<https://arxiv.org/pdf/2412.11109>
- Phish-Master
<https://www.mdpi.com/2076-3417/15/22/12203>

В рамках исследования предполагается разработать и оценить систему, которая помогает определить, использовался ли генеративный ИИ на каком-либо этапе создания, модификации или масштабирования email-спама. Такая система не должна ограничиваться бинарной классификацией “письмо написано ИИ / письмо написано человеком”. Более важным результатом является способность выявлять разные формы AI-assisted происхождения: полностью сгенерированный текст, частично отредактированное письмо, автоматически созданные вариации, признаки многоэтапной сборки, а также кампании, в которых ИИ мог применяться для повышения масштаба, разнообразия или убедительности сообщений.

Ожидается, что итоговое решение будет анализировать как отдельное email сообщение, так и группу похожих сообщений в рамках возможной кампании. Для отдельного письма система должна определять вероятность того, что оно является спамом или фишингом, а также оценивать наличие признаков AI-assisted происхождения. Для кампаний система должна помогать выявлять автоматизированную вариативность, повторяющиеся

паттерны, признаки масштабирования и возможное использование генеративных инструментов для создания множества похожих, но не идентичных сообщений.

Результатом работы должен стать прототип аналитического модуля, который может использоваться как дополнительный слой поверх существующей антиспам-системы. Такой модуль должен не просто выдавать итоговый класс, а помогать аналитику понять, почему письмо или кампания выглядят подозрительно: какие элементы могли быть сгенерированы, отредактированы или автоматически скомбинированы, насколько уверена система в выводе. Качество решения предполагается оценивать не только по стандартным метрикам классификации, таким как precision, recall, F1-score и ROC-AUC, но и по прикладным критериям: полнота объяснений, устойчивость к маскировке AI-generated признаков, способность работать с частично сгенерированными письмами и способность выявлять кампании, а не только отдельные сообщения. Особое внимание следует уделить ложным срабатываниям на легитимные корпоративные письма, маркетинговые рассылки и автоматические уведомления, поскольку они могут быть стилистически похожи на AI-assisted сообщения.

В завершение исследования должны быть сформулированы практические рекомендации по применению подхода в антиспам-системах и SOC процессах.

Смежная тема прикладного характера:

Разработка explainable AI-assisted spam enrichment module для анти-спамсистемы или SOC-процесса. Модуль должен определять вероятность использования генеративного ИИ при создании письма или кампании, группировать похожие сообщения, выделять подозрительные элементы и помогать аналитикам принимать решения на основе объяснимых признаков.